

Universidade Federal de Santa Catarina
Pós-Graduação em Engenharia de Transportes e Gestão Territorial

Engenharia de Tráfego

Redes neurais artificiais aplicadas a transportes.

Aluno: Ivan Ogasawara

Florianópolis, 13 de maio de 2015

Sumário

| | | |
|----------|---|----------|
| 1 | Introdução | 1 |
| 2 | Rede Neural Artificial - RNA | 1 |
| 2.1 | Conceitos básicos de Aprendizagem Automática | 2 |
| 2.2 | Estrutura de uma RNA | 2 |
| 3 | RNA aplicadas a transportes | 5 |
| 3.1 | Métodos de RNA para classificação baseada no comprimento do veículo usando saídas de um único laço indutivo | 6 |
| 3.2 | RNA baseada em modelo de predição de fluxo de tráfego | 7 |
| 4 | Conclusões | 8 |
| | Referências | 8 |

1 Introdução

Com a evolução da tecnologia nos últimos anos, a inteligência artificial (conhecida também pela sigla IA, ou por AI, sigla do termo em inglês) em especial, muitas áreas de pesquisa e empresariais passaram a utilizar métodos de inteligência artificial como um diferencial de seu trabalho ou, até mesmo, na resolução de problemas que antes eram computacionalmente ou operacionalmente inviáveis.

A IA, hoje, está espalhada pelos diversos serviços consumidos, de maneira transparente, como por exemplo os sistemas de recomendações utilizados pelos principais comércios eletrônicos e pelos motores de busca na *Internet* (Google, Yahoo, Bing, etc).

O presente trabalho tem como objetivo tratar sobre o tema das Redes Neurais Artificiais (conhecido também como RNA, ou por ANN, sigla do termo em inglês) aplicadas à área de transportes.

Na sequência, serão abordados os conceitos sobre RNA e, em seguida, algumas aplicações deste método na área de transportes.

2 Rede Neural Artificial - RNA

As Redes Neurais Artificiais (RNAs), são métodos de aprendizagem automática ou aprendizagem de máquina (também conhecido pelo termo em inglês *Machine Learning*) são robustos para trabalhar com dados de treino com ruído (erros) e são bastante utilizadas para resolver problemas como: reconhecimento automático de alvos, reconhecimento de caracteres, robótica, diagnóstico médico, sensoriamento remoto, processamento de voz, biometria etc.

O computador tem um poder de processamento superior ao do cérebro humano, ele compreende 10^9 transistores com um tempo de troca de 10^{-9} segundos, enquanto o cérebro humano contém 10^{11} neurônios, mas com um tempo de troca próximo a 10^{-3} segundos (KRIESEL, 2008).

As redes neurais artificiais (RNAs), em parte, foram inspiradas pelos estudos e observações feitas das complexas teias de neurônios interconectados e, analogicamente, as RNAs são construídas de um conjunto denso interconectado de unidades simples (MITCHELL, 1997).

Basicamente, existem dois ramos de estudos das RNAs, um grupo interessado em processos de aprendizagem em modelos biológicos e, outro grupo, interessado em algoritmos de aprendizado automático independentes dos processos biológicos (MITCHELL, 1997). No

presente trabalho, os conceitos apresentados estão relacionados mais com as propostas do último grupo.

2.1 Conceitos básicos de Aprendizagem Automática

Alguns conceitos básicos são necessário para tratar de temas relacionados à aprendizagem automática (conhecida também por ML, sigla do termo em inglês) e serão apresentados na sequência.

A aprendizagem de conceitos (*concept learning*) ou aprendizagem de categorias (*category learning*) são conceitos ou categorias utilizados para classificar objetos. Mitchell (1997, p. 20, 23) descreve a aprendizagem de conceitos como uma tarefa de buscar através de um espaço pré-definido de hipóteses potenciais com o objetivo de encontrar a hipótese que melhor se ajusta aos exemplos de treino.

As hipóteses são as possíveis funções que podem ser utilizadas para responder a questão do problema analisado. Por exemplo, em um jogo de damas, as hipóteses são os movimentos possíveis que o jogar terá para realizar.

O conjunto de itens sobre os quais os conceitos são definidos (MITCHELL, 1997, p. 22) são conhecidos como instâncias (*Instance*). Estas possuem atributos que serão utilizados na avaliação das hipóteses, por exemplo humidade do ar, temperatura, pressão atmosférica, etc.

O conceito ou função a ser aprendido é chamado de conceito alvo (*target concept* ou *target function*), em outras palavras, é o que se deseja aprender a estimar dado um conjunto de dados (MITCHELL, 1997, p. 22). Por exemplo, "Choverá amanhã?".


A aprendizagem ocorre através dos treinos (*training*) sobre os exemplos. Nesses treinos, estão presentes exemplos positivos e negativos do conceito alvo. Após os treinos, a eficiência do modelo aprendido pode ser mensurado através de um conjunto de dados de teste (*testing*).

2.2 Estrutura de uma RNA

Um tipo de sistema RNA é baseado em uma unidade chamada perceptron e sua estrutura pode ser visto através da Figura 1. Como pode ser visto na figura, o perceptron recebe como entrada um vetor com dados reais e um vetor com pesos, onde cada peso está vinculado a um item do vetor de entrada. A partir da entrada, é calculado uma combinação linear desses valores, retornando 1 se o valor resultante for maior que o valor definido de limite (*threshold*), caso contrário, retorna -1 (MITCHELL, 1997, p. 87).


Os perceptrons podem representar todas as funções booleanas primárias como as funções: *AND*, *OR*, *NAND* (\neg *AND*), *NOR* (\neg *OR*). Algumas funções booleanas, como por exemplo a função *XOR*, não pode ser representada por um único perceptron, por seus resultados não serem linearmente separáveis (2 (b)). Um exemplo de resultados de uma função linearmente separável pode ser observada na Figura 2 (a).

Figura 1: Perceptron (MITCHELL, 1997, p. 87)



A Figura 2 (a) mostra os resultados, positivos e negativos, dado certo *threshold*

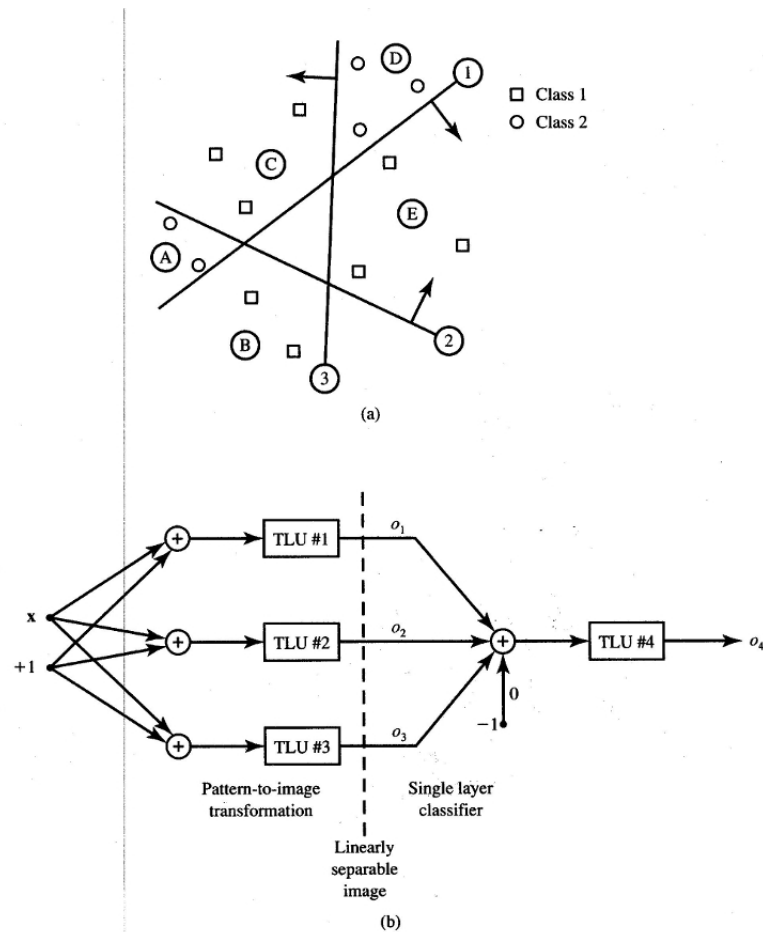
Figura 2: Plano de decisão por dois tipos de perceptrons (MITCHELL, 1997, p. 87)



Os perceptrons sozinhos podem somente expressar planos de decisão linear. Para expressar planos de decisão não lineares é necessário utilizar uma rede multicamadas. A Figura 3 ilustra a estrutura de uma classificação de padrões linearmente não separáveis.

Um exemplo prático simples da criação de uma RNA, pode ser feito através da biblioteca (SCHAUL et al., 2010), disponível para a linguagem de programação *Python*. No *Listing 1* foi criado um conjunto de dados para a função *XOR* e uma rede com o método de aprendizagem com *Backpropagation* e, em seguida, é executado o treino da rede com o conjunto de dados. O

Figura 3: Classificação de padrões não lineares (ZURADA, 1992, p. 166)



resultado do primeiro treino é valor do erro proporcional. O segundo treino, trabalha até a rede convergir e o resultado é uma lista com todos os valores de erros proporcionais encontrados.

Listing 1: Exemplo de criação e treino de uma rede neural

```
>>> from pybrain.datasets import SupervisedDataSet
>>> from pybrain.supervised.trainers import BackpropTrainer
>>> from pybrain.tools.shortcuts import buildNetwork
>>> from pybrain.structure import TanhLayer

>>> ds = SupervisedDataSet(2, 1)
>>> ds.addSample((0, 0), (0,))
>>> ds.addSample((0, 1), (1,))
>>> ds.addSample((1, 0), (1,))
>>> ds.addSample((1, 1), (0,))

>>> net = buildNetwork(2, 3, 1, bias=True, hiddenclass=TanhLayer)
```

```
>>> trainer = BackpropTrainer(net, ds)
>>> trainer.train()
0.31516384514375834
>>> trainer.trainUntilConvergence()
[2.4976290401821779 ... 0.00018292786169894166]
```

3 RNA aplicadas a transportes

O uso das RNAs é vasto e muito presente nos dias atuais. Na área de transportes também existem diversos problemas que podem ser resolvidos através das RNAs. Nessa seção serão apresentados algumas aplicações e referencias a outras pesquisas feitas sobre esse tema.

As técnicas de inteligencia artificial permitem o uso de aplicações para o gerenciamento completo de sistemas de transportes - veículos, motoristas, infraestrutura e vias (ŠUSTEKOVÁ; KNUTELSKÁ, 2013, p. 266).

Antes de decidir o uso de um método de RNA para a resolução de um determinado, é importante conhecer as vantagens e desvantagens dessa abordagem.

Šusteková e Knutelská (2013, p. 268) menciona algumas vantagens no uso das RNAs:

- Permitem o processamento de dados paralelos;
- Não precisam de nenhuma informação sobre a estrutura do processo, ele aprende e não precisa ser reprogramado;
- Trabalhando junto com algoritmos de aprendizagem, podem ser adaptados para realizar alterações nos seus parâmetros;
- São apropriados para identificação, classificação e ordenação de modelos - usados em reconhecimento de placas de sinalização de trânsito, placas de identificação veicular, reconhecimento de rostos, etc;
- Sem algoritmos de aprendizagem deixam o processamento mais rápido;
- Permitem redução de dados à uma dimensão menor;
- São aproximadores universais: permitem a aproximação de qualquer função com qualquer acurácia.

Sobre as disvantagens do uso das RNAs, Šusteková e Knutelská (2013, p. 268) menciona que:

- RNAs necessitam de um suporte grande de recursos computacionais;
- A implementação é feita por experimentos e erros, aumentando a demanda de tempo para a solução;
- A arquitetura de RNAs são diferentes da arquitetura dos microprocessadores, por isso necessitam ser emuladas;

3.1 Métodos de RNA para classificação baseada no comprimento do veículo usando saídas de um único laço indutivo

Nos Estados Unidos da América, dos veículos registrados, 4% deles são veículos longos, porém de todos os veículos envolvidos em acidentes fatais 8% são veículos longos (NCSA, 2005). A detecção, então, do volume de tráfego se mostra muito importante para a operação de tráfego, projeto de pavimento e planejamento de transporte. Para resolver esse problema, utilizando os recursos disponíveis (um único laço na faixa), o Laboratório *STAR Lab* desenvolveu um método de RNA para a estimativa de volume utilizando um único laço (ZHANG; WANG; WEI, 2006). Um dos grandes desafios de estimar a classificação do veículo com um único laço indutivo, é a falta da informação referente à velocidade.

A proposta da pesquisa foi usar RNAs para a captura da relação entre variáveis medidas de um único laço indutivo e os volumes de veículos classificados sob várias condições de tráfego.

Foi desenhada uma rede de três camadas, pré-alimentação (*feed-forward*) com a arquitetura de retro-propagação *back-propagation* (BP) através do algoritmo *gradient descent*.

Nesse estudo, os veículos foram divididos em 4 classes que são consistentes com as 4 faixas de classificação usado pelo WSDOT (*Washington State Department of Transportation*), como pode ser visto na Figura 4.

Figura 4: Classificação de veículos por comprimento de WSDOT (ZHANG; WANG; WEI, 2006, p. 6)

TABLE 1 Four Length-Based Vehicle Categories Used By The WSDOT

| Classes | Range of length | Vehicle types |
|---------|---|---|
| Bin1 | Less than 26 ft (7.92 m) | Cars, pickups, and short single-unit trucks |
| Bin2 | From 26 ft (7.92 m) to 39 ft (11.89 m) | Cars and trucks pulling trailers, long single-unit trucks |
| Bin3 | From 40 ft (12.19 m) to 65 ft (19.81 m) | Combination trucks |
| Bin4 | Longer than 65 ft (19.81 m) | Multi-trailer trucks |

Foi desenhada e configurada uma RNA para cada classificação de veículo e a rede foi

treinada e testada usando dados coletados de uma estações com detectores de laço indutivo na área I-5 na grande *Seattle*.

Os resultado obtidos indicaram que o método de RNA proposto funcionou estável e efetivamente para as estações estudadas. Para concluir que esses resultados possam ser espacialmente transferíveis, outros testes devem ser realizados em estações de outras áreas.

3.2 RNA baseada em modelo de predição de fluxo de tráfego

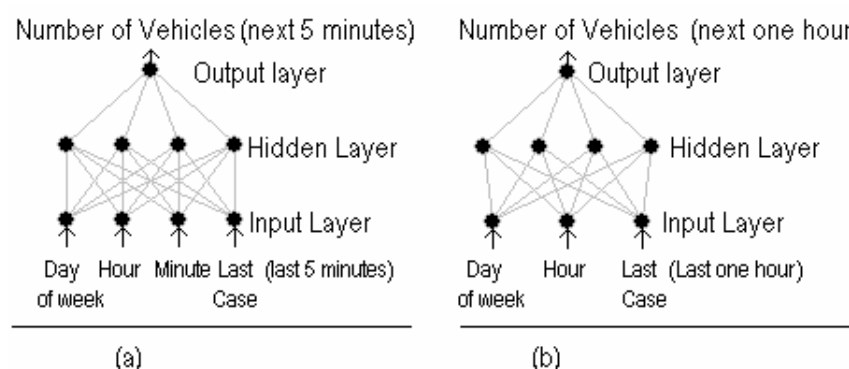
A pesquisa realizada por (ÇETINER; SARI; BORAT, 2010), teve como objetivo utilizar dados históricos sobre as condições de tráfego da cidade de Istambul para a predição do volume de tráfego através de métodos de RNAs.

Os dados analisados foram providos pelo ISBAK, a organização semi-governamental responsável pela manutenção de estradas, incluindo junções de tráfego em Istambul. O conjunto de dados registrados no intervalo de 5 minutos consiste no número de veículos passando sobre o RTMS (*Remote Traffic Microwave Sensor*) 12 em um dia, hora e minuto específico. Os dados foram coletados entre o dia primeiro de janeiro de 2006 e o último dia de dezembro do mesmo ano, resultando em um conjunto de 130.701 conjunto de dados.

O propósito principal desse estudo foi investigar a viabilidade de aplicação de técnicas de RNAs para fechar a lacuna nas tomadas de decisões no controle de tráfego da cidade, realizado apenas pelos conhecimentos empírico das pessoas.

Foram criadas duas RNAs, uma para estimar os próximos 5 minutos e outra para estimar a próxima hora. A estrutura das redes podem ser vistas na Figura 5.

Figura 5: Estrutura de RNA adotadas (ÇETINER; SARI; BORAT, 2010, p. 275)



As RNAs treinadas convergiram ao resultado em menos de 1 minuto. Ambas redes produziram um bom resultado e os coeficientes de correlação variaram entre 0,85 e 0,95 com os dados de testes e mais de 0,95 com os dados de treino.

4 Conclusões

Os métodos de redes neurais artificiais RNAs podem contribuir muito para a resolução de muitos problemas na área de transportes, como por exemplo no reconhecimento de placas de sinalização de trânsito, placas de identificação veicular, reconhecimento de rostos, classificação de veículos, etc.

As RNAs podem ser consideradas na resolução de problemas, como classificação e estimativas, quando o dado de entrada possui ruídos (erros) ou quando existe a necessidade de ter respostas em tempo real.

Um meio de aplicar os métodos de RNA para a resolução de um problema pode ser feito através da linguagem *Python* juntamente com a biblioteca *PyBrain*. Além desta, podem ser encontradas outras bibliotecas em Python para trabalhar com RNA, como por exemplo: *FRNA*, *NeuroLab*, *NearPy*, etc.

Os estudos, aqui descritos, de aplicações de RNAs em transportes são boas referências de metodologias na aplicação do tema. No primeiro trabalho, sobre classificação baseada no comprimento do veículo através de um único laço indutivo, foi desenvolvido uma pesquisa utilizando RNA para analisar dados de estações com sistemas de um único laço indutivo, na área I-5 da grande *Seattle*, para estimar a classificação dos veículos. Os resultados desse trabalho foram positivos, abrindo novas perspectivas de estudos em outras áreas, para ampliar as conclusões do trabalho.

O segundo trabalho analisado foi a pesquisa sobre o estudo da aplicação de duas estruturas RNAs para estimar o volume de tráfego da cidade de Istambul, uma para os próximos 5 minutos e a outra para a próxima hora. Os resultados foram otimistas, tendo os coeficientes de correlação variando entre 0,85 e 0,95 para os dados de teste.

Referências

- ÇETINER, B. G.; SARI, M.; BORAT, O. A neural network based trafficflow prediction model. *Mathematical and Computational Applications*, v. 15, n. 2, p. 269–278, 2010.
- KRIESEL, D. *A Brief Introduction to Neural Networks, Zeta version (2007)*. 2008.
- MITCHELL, T. M. *Machine Learning*. [S.l.]: McGraw-Hill Higher Education, New York, NY, USA, 1997.
- NCSA (National Center for Statistics and Analysis). *Traffic Safety Facts 2003*. [S.l.], 2005.
- SCHAUL, T. et al. PyBrain. *Journal of Machine Learning Research*, 2010.
- ŠUSTEKOVÁ, D.; KNUTELSKÁ, M. Artificial intelligence applications especially the neural networks use in the road transport. *Proceedings of the 13th International Conference "Reliability and Statistics in Transportation and Communication"*, 2013.

ZHANG, G.; WANG, Y.; WEI, H. Artificial neural network method for length-based vehicle classification using single-loop outputs. *Transportation Research Record: Journal of the Transportation Research Board*, Trans Res Board, v. 1945, n. 1, p. 100–108, 2006.

ZURADA, J. M. *Introduction to artificial neural systems*. [S.l.]: West St. Paul, 1992.